

# 介紹



圖片的辨識大家已經做得有點膩了！



還有沒有什麼可以玩的呢？人類的智慧活動除了『判斷』(辨識) 好像還有另外一個，那就是『**創作**』，  
『**創作**』才是最終極的智慧活動的形式



如何創作呢？還是要從『人』出發，思考『人類』創作的過程

# 人類創作過程





?


我們如何把人類創作的過程套用到深度學習呢？

# AI創作過程

隨機數列 (突發靈感)



反向神經網路



成品



之前我們在辨別事物的時候神經數目都是『**縮小**』，因為是『**組合**』的概念，但是現在要『**增加**』，因為是將靈感『**擴充**』



深度學習的精髓是透過與『**正確答案**』的距離來調整『**模型參數**』，但是我們在創作的情況下，如何定義『**正確**』？無法定義正確，我們就無法調整參數

# 救星


## GAN之父 - Ian Goodfellow

這個人真的得好好介紹一下！就是他  
想出了**GAN**，讓整個深度學習界為之  
瘋狂，整個過程也曲折離奇，Ian  
Goodfellow 跟朋友在一個**酒館**慶祝  
的時候，剛好討論到生成圖片的困  
境，那時候一個衝擊性的主意突然閃  
過他的腦袋！於是他馬上回家開始寫  
程式一直到天亮，那天的那個主意就  
是**GAN**




# GAN


隨機數列 (突發靈感)




反向神經網路




我們喜歡叫他  
Generator(創作家)




成品



正向神經網路



我們喜歡叫他  
Discriminator(鑑賞家)



0 (爛)  
1 (好)

GAN精髓

用另外一個深度網路來判定成品到底好或者壞，這也是為何我們稱它為GAN(Generative Adversarial Network)，生成式對抗模型，由兩個神經網路互相對抗而組成

# 訓練步驟



## 步驟1 訓練鑑賞家

**訓練目標** 鑑賞家能分辨出真假

**操作方式** 從**訓練資料集**抽出**真正樣本**以及讓**現在的創作家**創作出**假樣本**，真正樣本標註答案**1(真)**，假樣本標註答案**0(假)**



## 步驟2 訓練創作家


**訓練目標** 創作家的作品能被評斷為真

**操作方式** 讓創作家創作出**假樣本**，並且給出**答案1(真)**，利用和真答案的距離回頭調整創作家的參數



# GAN訓練過程





隨著創作家和鑑賞家的訓練，整個過程會經歷什麼狀態呢？



**狀態1.** 創作家的作品是跟真的作品差很多的，所以在訓練的時候鑑賞家可以輕易訓練出『真』和『偽』的差別



**狀態2.** 創作家進步了，但是還是跟真正的作品有差距，所以鑑賞家也一起進步了，還是可以找到『真』和『偽』的差別



**狀態3.** 最終狀態，偽作跟真正的作品幾乎沒差距了，所以到這個平衡狀態，你的鑑賞家已經無法再訓練了，這時候候創作家的作品就像真的作品一樣

# GAN注意事項



跟其他深度學習的訓練不一樣，其他深度學習的訓練Loss會持續下降，但是GAN最後是到一個穩定狀態，創作家的圖(標註為假)和真圖(標註為真)幾乎長得一樣，這時候鑑賞家的訓練已經停滯了，所以訓練Loss會停留在某個數字區間，不會無止盡往下降




因此訓練該到什麼時候為止呢？我建議觀察兩點

1. 鑑賞家和創作家的Loss都差不多平穩
2. 真的觀察一下創作家創作圖看看合不合理



# 手寫數字




第一個練習先從手寫數字開始，  
MNIST資料集是 28 x 28 的手寫數字



最後成果

# 條件式GAN

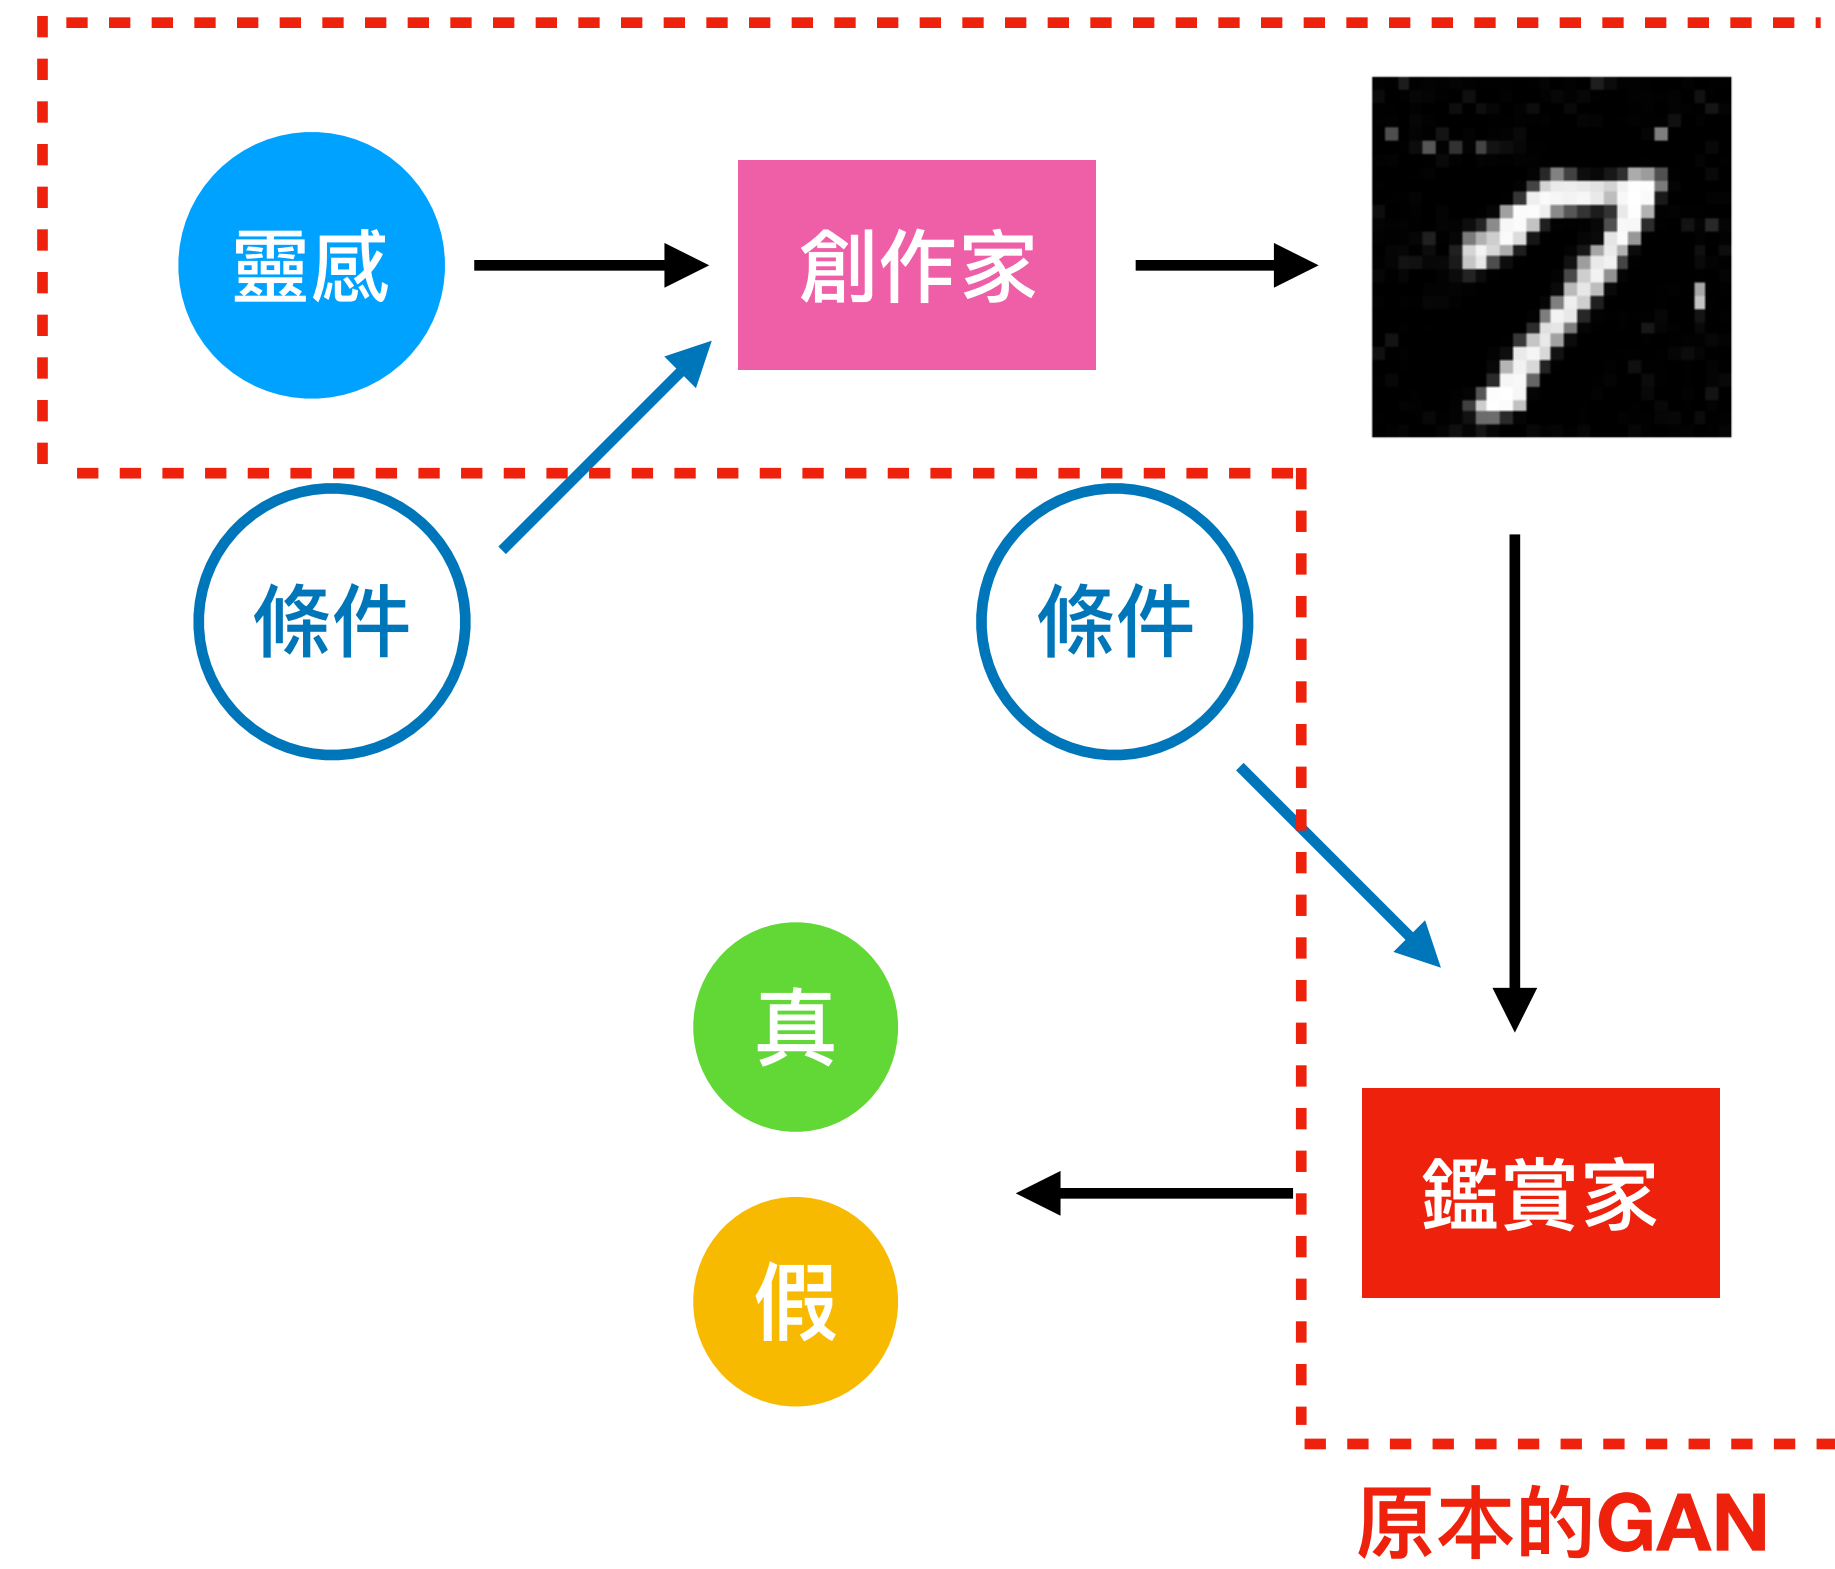


我們已經學會基本的GAN了，但我有個小問題，就是我們的創作家基本上只管真假，盡量創作出『真』，但並不能控制他到底要寫0 - 9 的哪一個

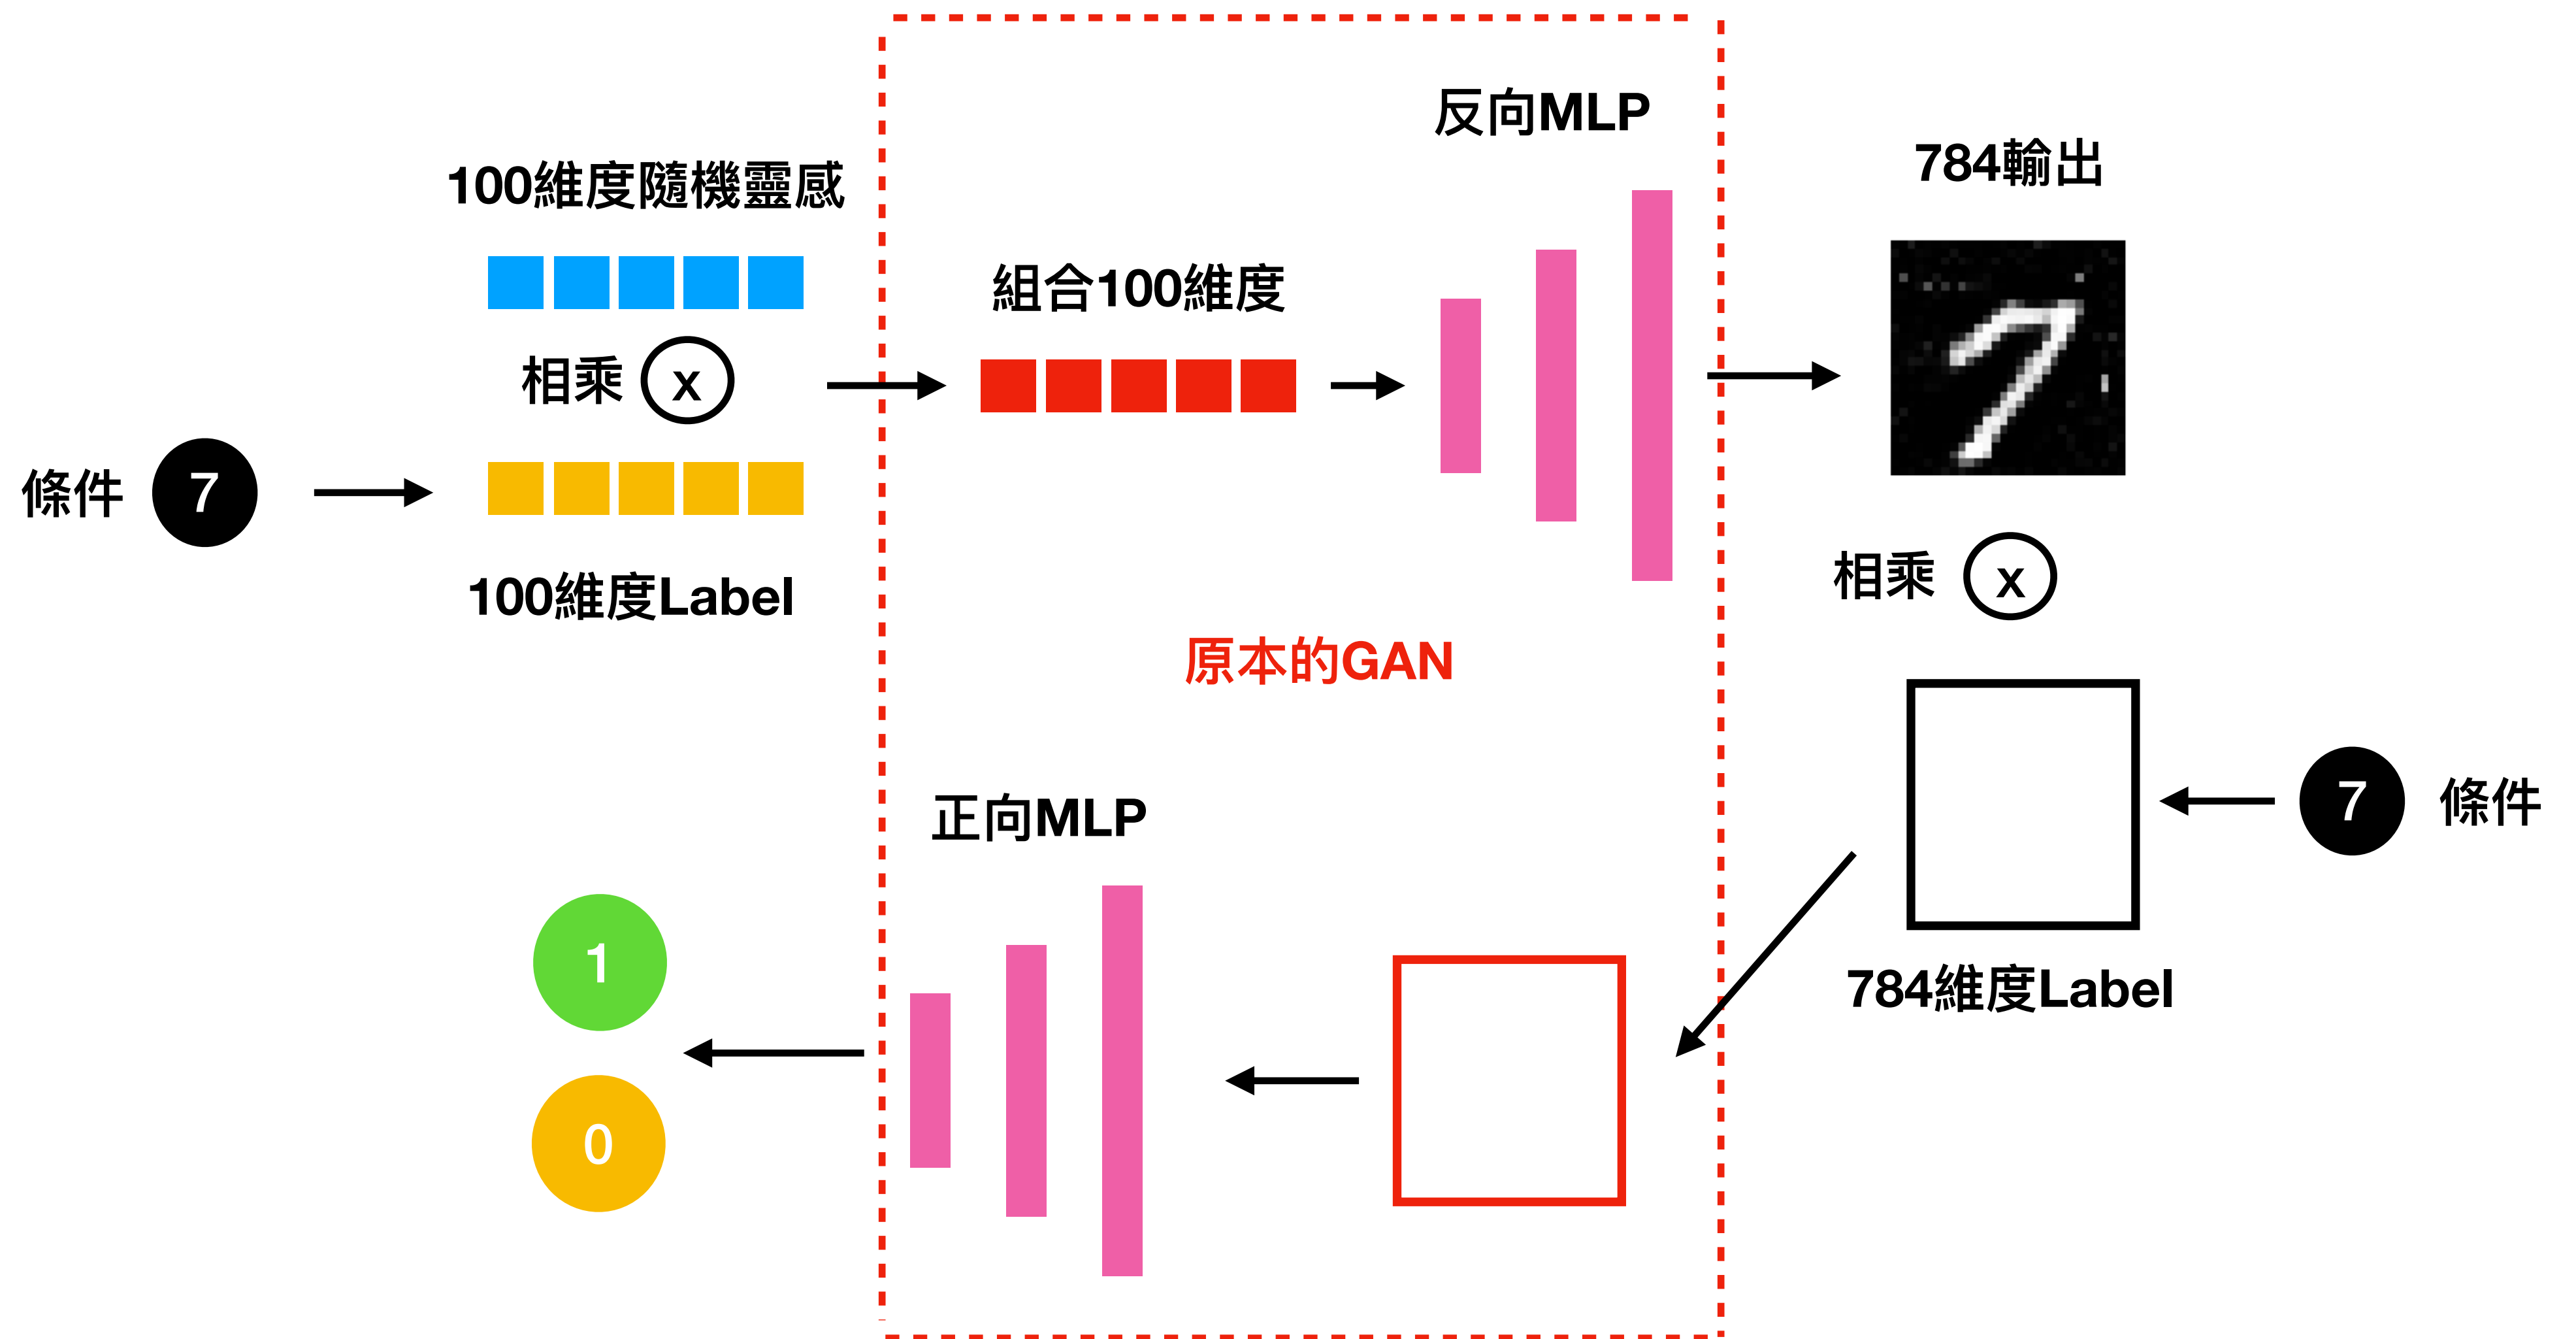


條件式 GAN (conditional GAN) 就是來解決這個問題的，在帶入靈感的時候，我們就會額外限制要生成什麼樣的作品！

# 模型



# 模型詳細





# 其實



如果要簡單的了解CGAN，你會發現乘上 Label 的動作不就像『**卷積網路**』過濾的概念嗎！？針對該出現的給予『**正分數**』，不該出現的點給予『**負分數**』，對於『**靈感**』我們過濾出我們針對那個數字該考慮的靈感位置，對於『**判斷**』我們也給予每個位置一個過濾！

# GAN


隨機數列 (突發靈感)





反向神經網路




我們喜歡叫他  
Generator(創作家)




成品



正向神經網路



我們喜歡叫他  
Discriminator(鑑賞家)



0 (爛)  
1 (好)

GAN精髓

用另外一個深度網路來判定成品到底好或者壞，這也是為何我們稱它為GAN(Generative Adversarial Network)，生成式對抗模型，由兩個神經網路互相對抗而組成

# 訓練步驟



## 步驟1 訓練鑑賞家

**訓練目標** 鑑賞家能分辨出真假

**操作方式** 從**訓練資料集**抽出**真正樣本**以及讓**現在的創作家**創作出**假樣本**，真正樣本標註答案**1(真)**，假樣本標註答案**0(假)**



## 步驟2 訓練創作家


**訓練目標** 創作家的作品能被評斷為真

**操作方式** 讓創作家創作出**假樣本**，並且給出**答案1(真)**，利用和真答案的距離回頭調整創作家的參數



# GAN訓練過程





隨著創作家和訓練家的訓練，整個過程會經歷什麼狀態呢？



**狀態1.** 創作家的作品是跟真的作品差很多的，所以在訓練的時候鑑賞家可以輕易訓練出『真』和『偽』的差別



**狀態2.** 創作家進步了，但是還是跟真正的作品有差距，所以鑑賞家也一起進步了，還是可以找到『真』和『偽』的差別



**狀態3.** 最終狀態，偽作跟真正的作品幾乎沒差距了，所以到這個平衡狀態，你的鑑賞家已經無法再訓練了，這時候候創作家的作品就像真的作品一樣



# GAN注意事項



跟其他深度學習的訓練不一樣，其他深度學習的訓練Loss會持續下降，但是GAN最後是到一個穩定狀態，創作家的圖(標註為假)和真圖(標註為真)幾乎長得一樣，這時候鑑賞家的訓練已經停滯了，所以訓練Loss會停留在某個數字區間，不會無止盡往下降



因此訓練該到什麼時候為止呢？我建議觀察兩點

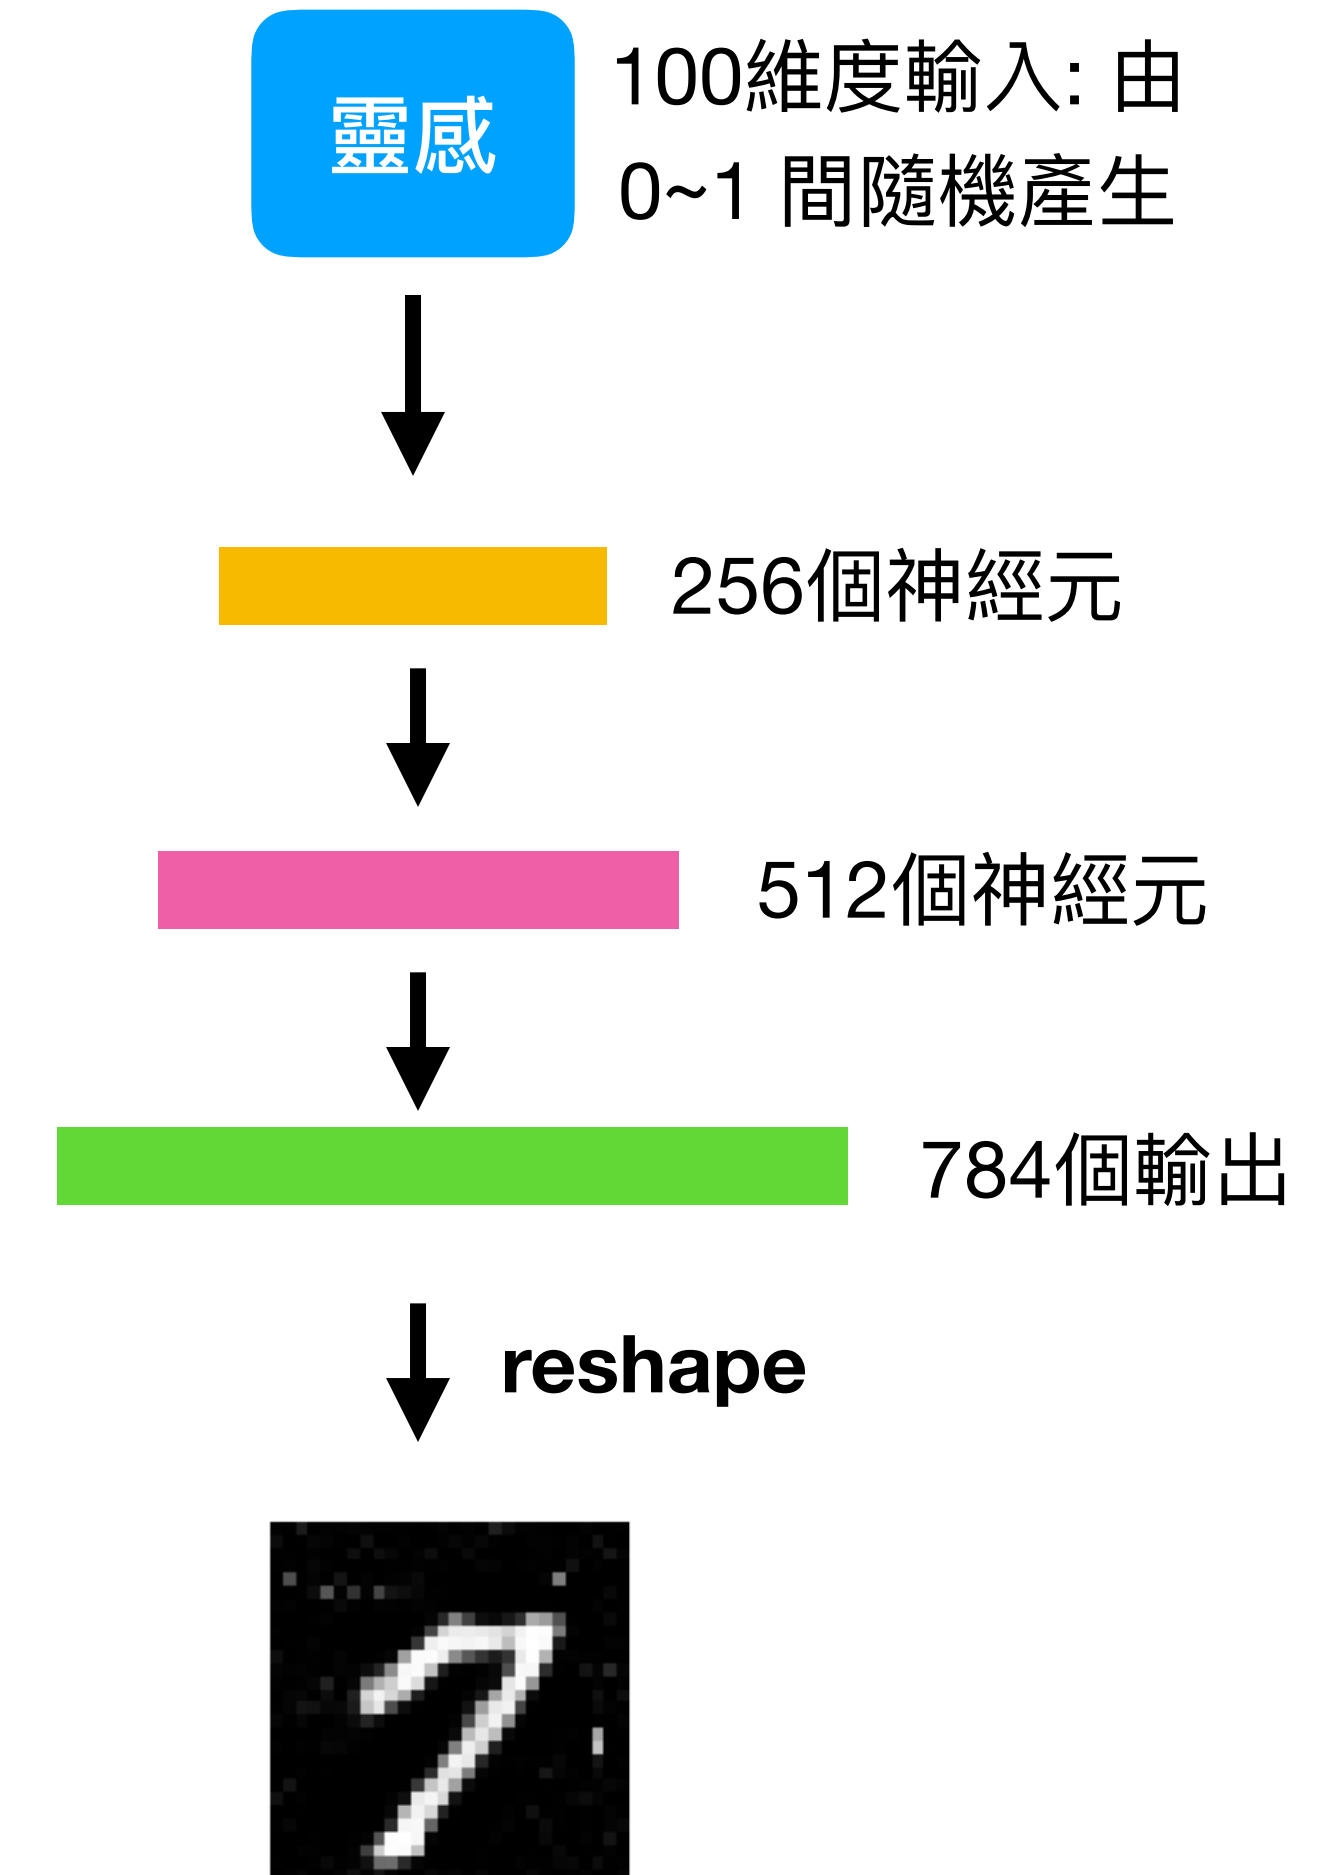
1. 鑑賞家和創作家的Loss都差不多平穩
2. 真的觀察一下創作家創作圖看看合不合理

# 創作家




我們使用最基礎的MLP來當我們的深度模型基礎


Layer (type)	Output Shape	Param #
dense_8 (Dense)	(None, 256)	25856
batch_normalization_3 (Batch Normalization)	(None, 256)	1024
dense_9 (Dense)	(None, 512)	131584
batch_normalization_4 (Batch Normalization)	(None, 512)	2048
dense_10 (Dense)	(None, 784)	402192
Total params: 562,704		
Trainable params: 561,168		
Non-trainable params: 1,536		



# $\tanh$



# Batch Normalization



**without BN**

模型也會像人類一樣，盡挑一些容易的事情做，譬如只輸出好寫的0和1

輸出 0 1 2 3 4 5

輸入 




**with BN**

藉由把輸入調整回正常區間，強迫模型一定要寫出別的數字


輸出 0 1 2 3 4 5

輸入 

# 流行衣物




作業我們來練習一下流行衣物如何  
請載入Keras的Fashion MNIST資料集




最後成果


# DCGAN



這是我們之前 G A N 的成果，不知道你有沒有發現，旁邊很多雜點，原因是這些雜點並不影響 **Discriminator** 分辨真假，所以對於 **Generator** 也不會用畢生力氣去抑制這些雜點

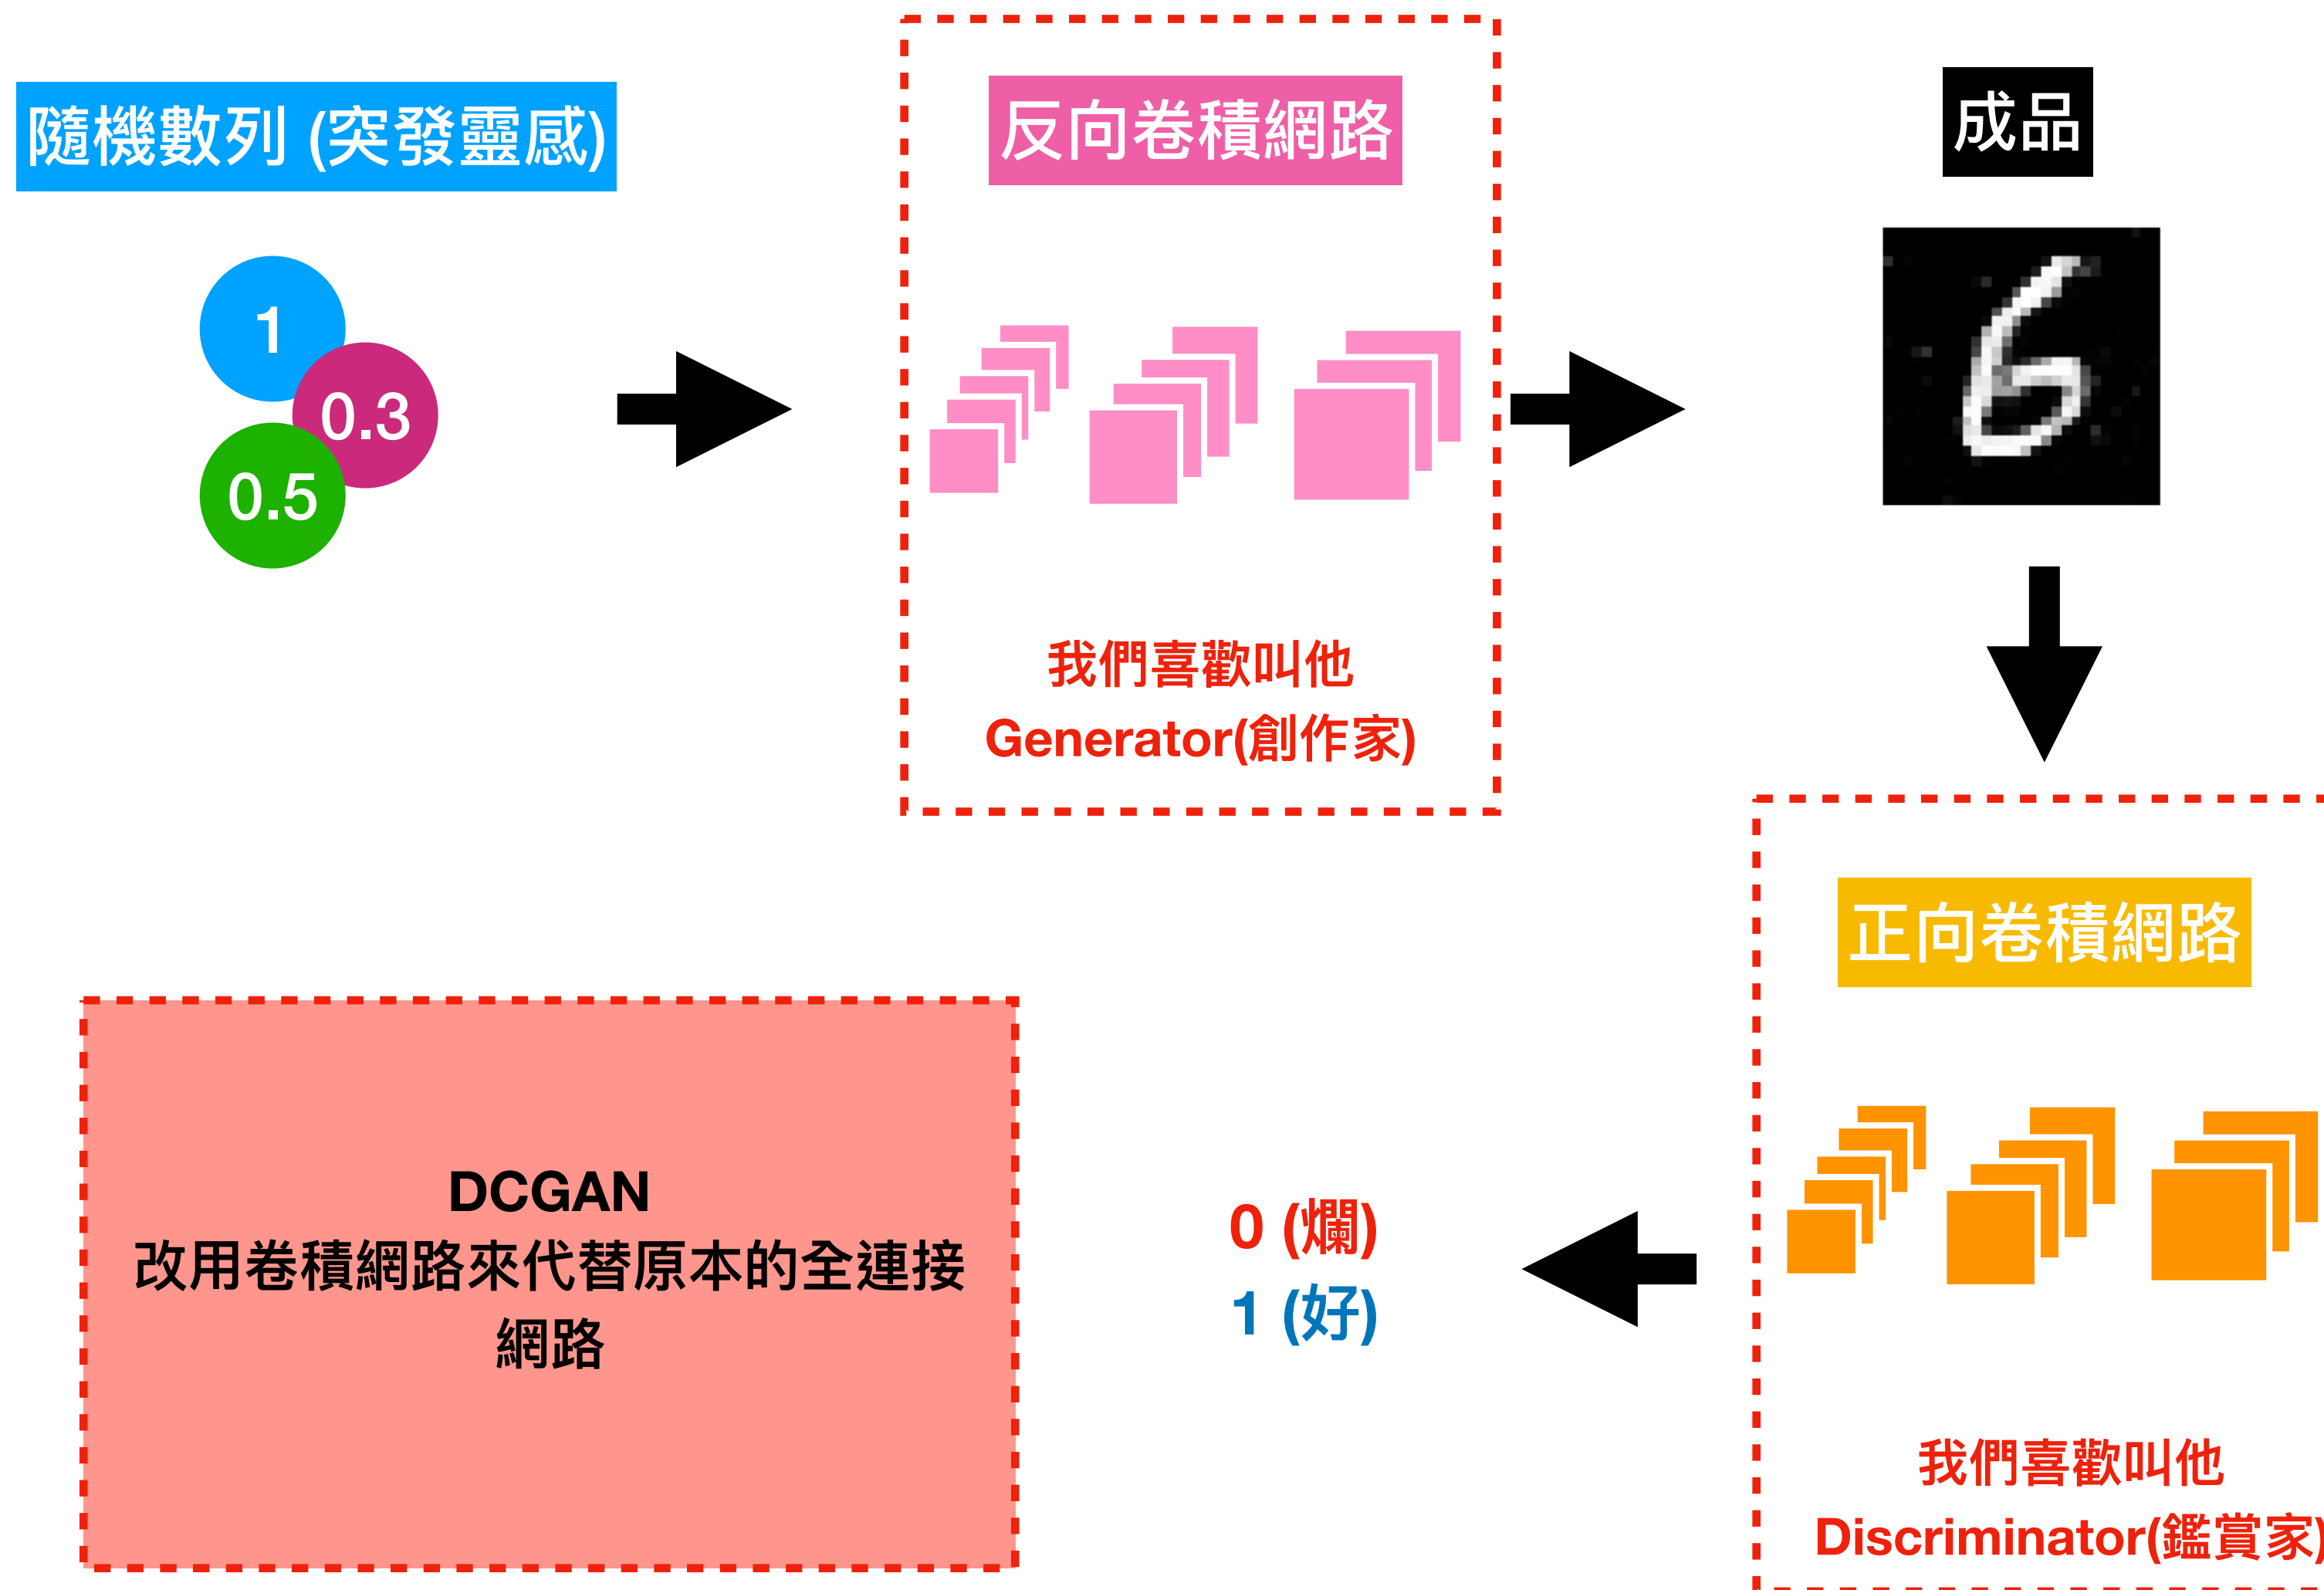


但也意味著你的 **Generator** 是以 **像素(點)** 的 Level 在生產，而不是抓住物品的 **精髓** 在生產



記得我們在 **MLP** 和 **CNN** 的時候也聊過這話題，**CNN** 比 **MLP** 厲害的地方就是他是真的抓住物品的精髓在判定東西，那**能不能把 **Discriminator** 和 **Generator** 都換成 卷積網路 呢?**


# DCGAN




# 卷積小複習



VGG16為例



卷積：特徵變多  
池化：寬高變小







# 反向卷積



反向卷積(又稱轉置卷積)



反向卷積：特徵<sup>變少</sup>  
反向池化：寬高<sup>變大</sup>




假設輸入  
 $14 \times 14 \times 32$

(2, 2)上採樣  
 $28 \times 28 \times 32$



16個filters的卷積  
 $28 \times 28 \times 16$



卷積: filters(特徵)增加  
轉置卷積: filters(特徵)<sup>減少</sup>

# 卷積步長




以前我們都靠著池化來縮小圖，但是你仔細想想，如果卷積的時候不要一格一格移，兩格兩格移不就可以達到池化的效果了嗎？



說的好，**步長=2的卷積** 其實就像 **卷積 + 池化** 的效果，但你發現我的卷積窗從以前常用的 (3, 3) 變成 (4, 4) 了，為什麼呢？

卷積窗(kernel) = (4, 4)

步長(stride) = 2




# 步長 + 卷積窗




但是如果你的卷積窗大小要開始變得不太一樣了，你會發現如果你的卷積窗大小如果不是**步長的整數倍**的話，會發生有些格子你考慮了多次，但有些格子考慮比較少次，**下面就是一個不整除的例子**

卷積窗(kernel) = (4, 4)

步長(stride) = 3




# 圖像翻譯



圖像翻譯的領域是把某一張圖像轉成為另外一個條件下的圖像，譬如把冬天轉換成夏天，把白天轉換成夜晚，我們今天來做個例子：把Google地圖轉換成對應的地形圖



在圖像翻譯的主題上使用GAN，我們給他一個特別的名字  
**PIX2PIX**

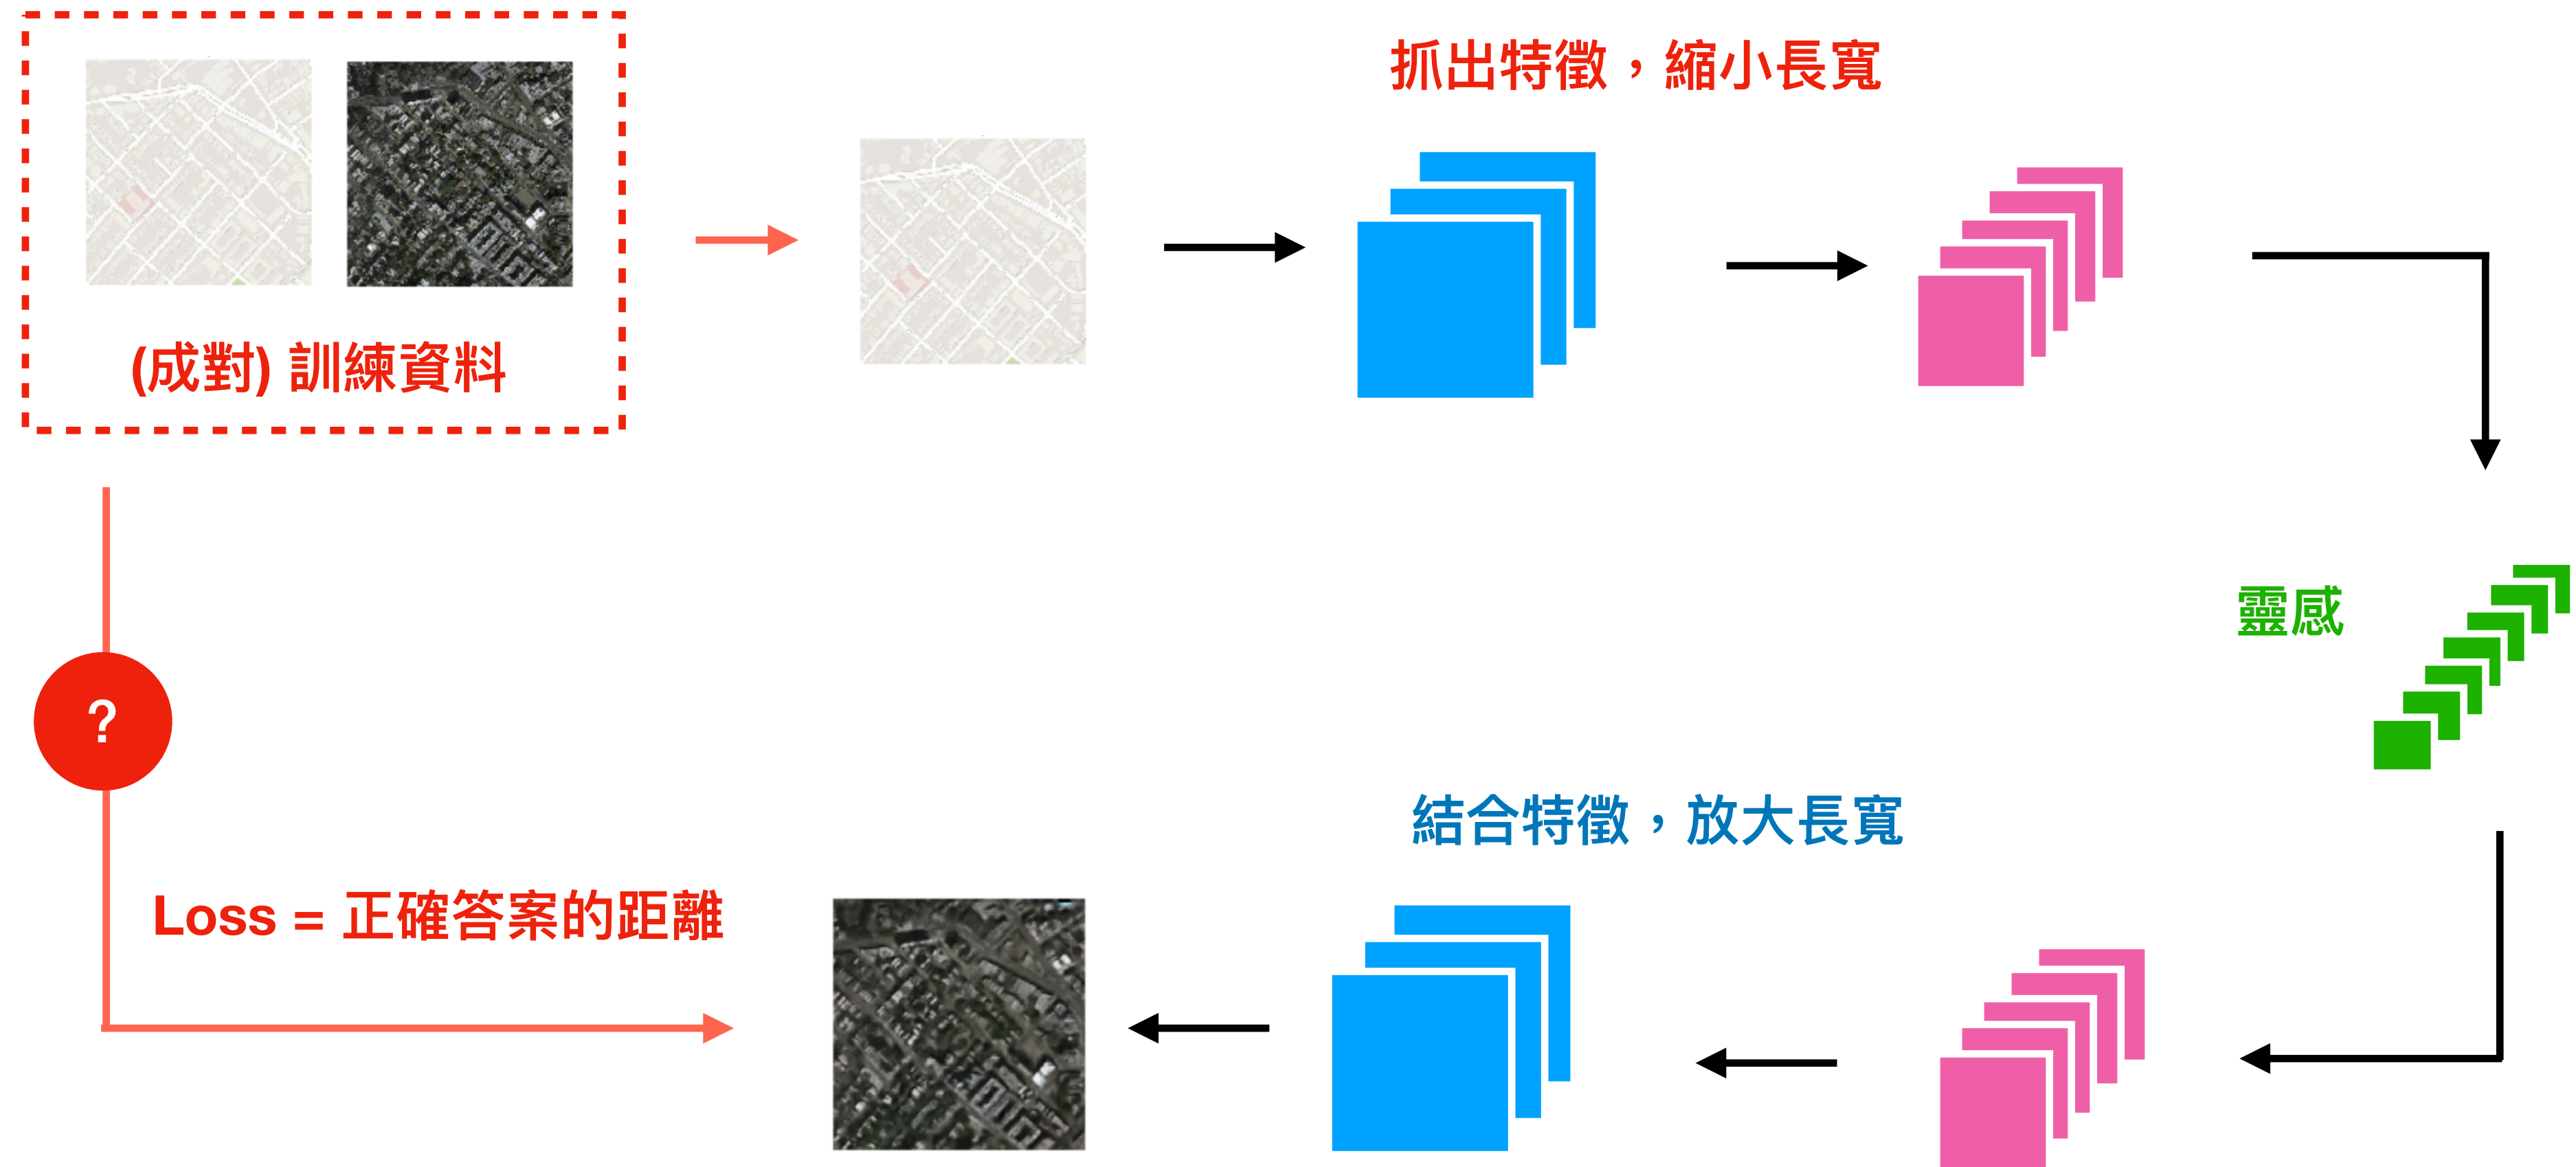


轉換成果：

原圖(左)


轉換後(右)

# 希望模型





# 以前Loss



以前這類模型我們叫 Encoder-Decoder，使用的 Loss 就是把真實的圖片和生產出來的圖片一個一個 pixel 比較差異，這種 Loss 我們叫它 **MSE Loss** 或 **MAE Loss**


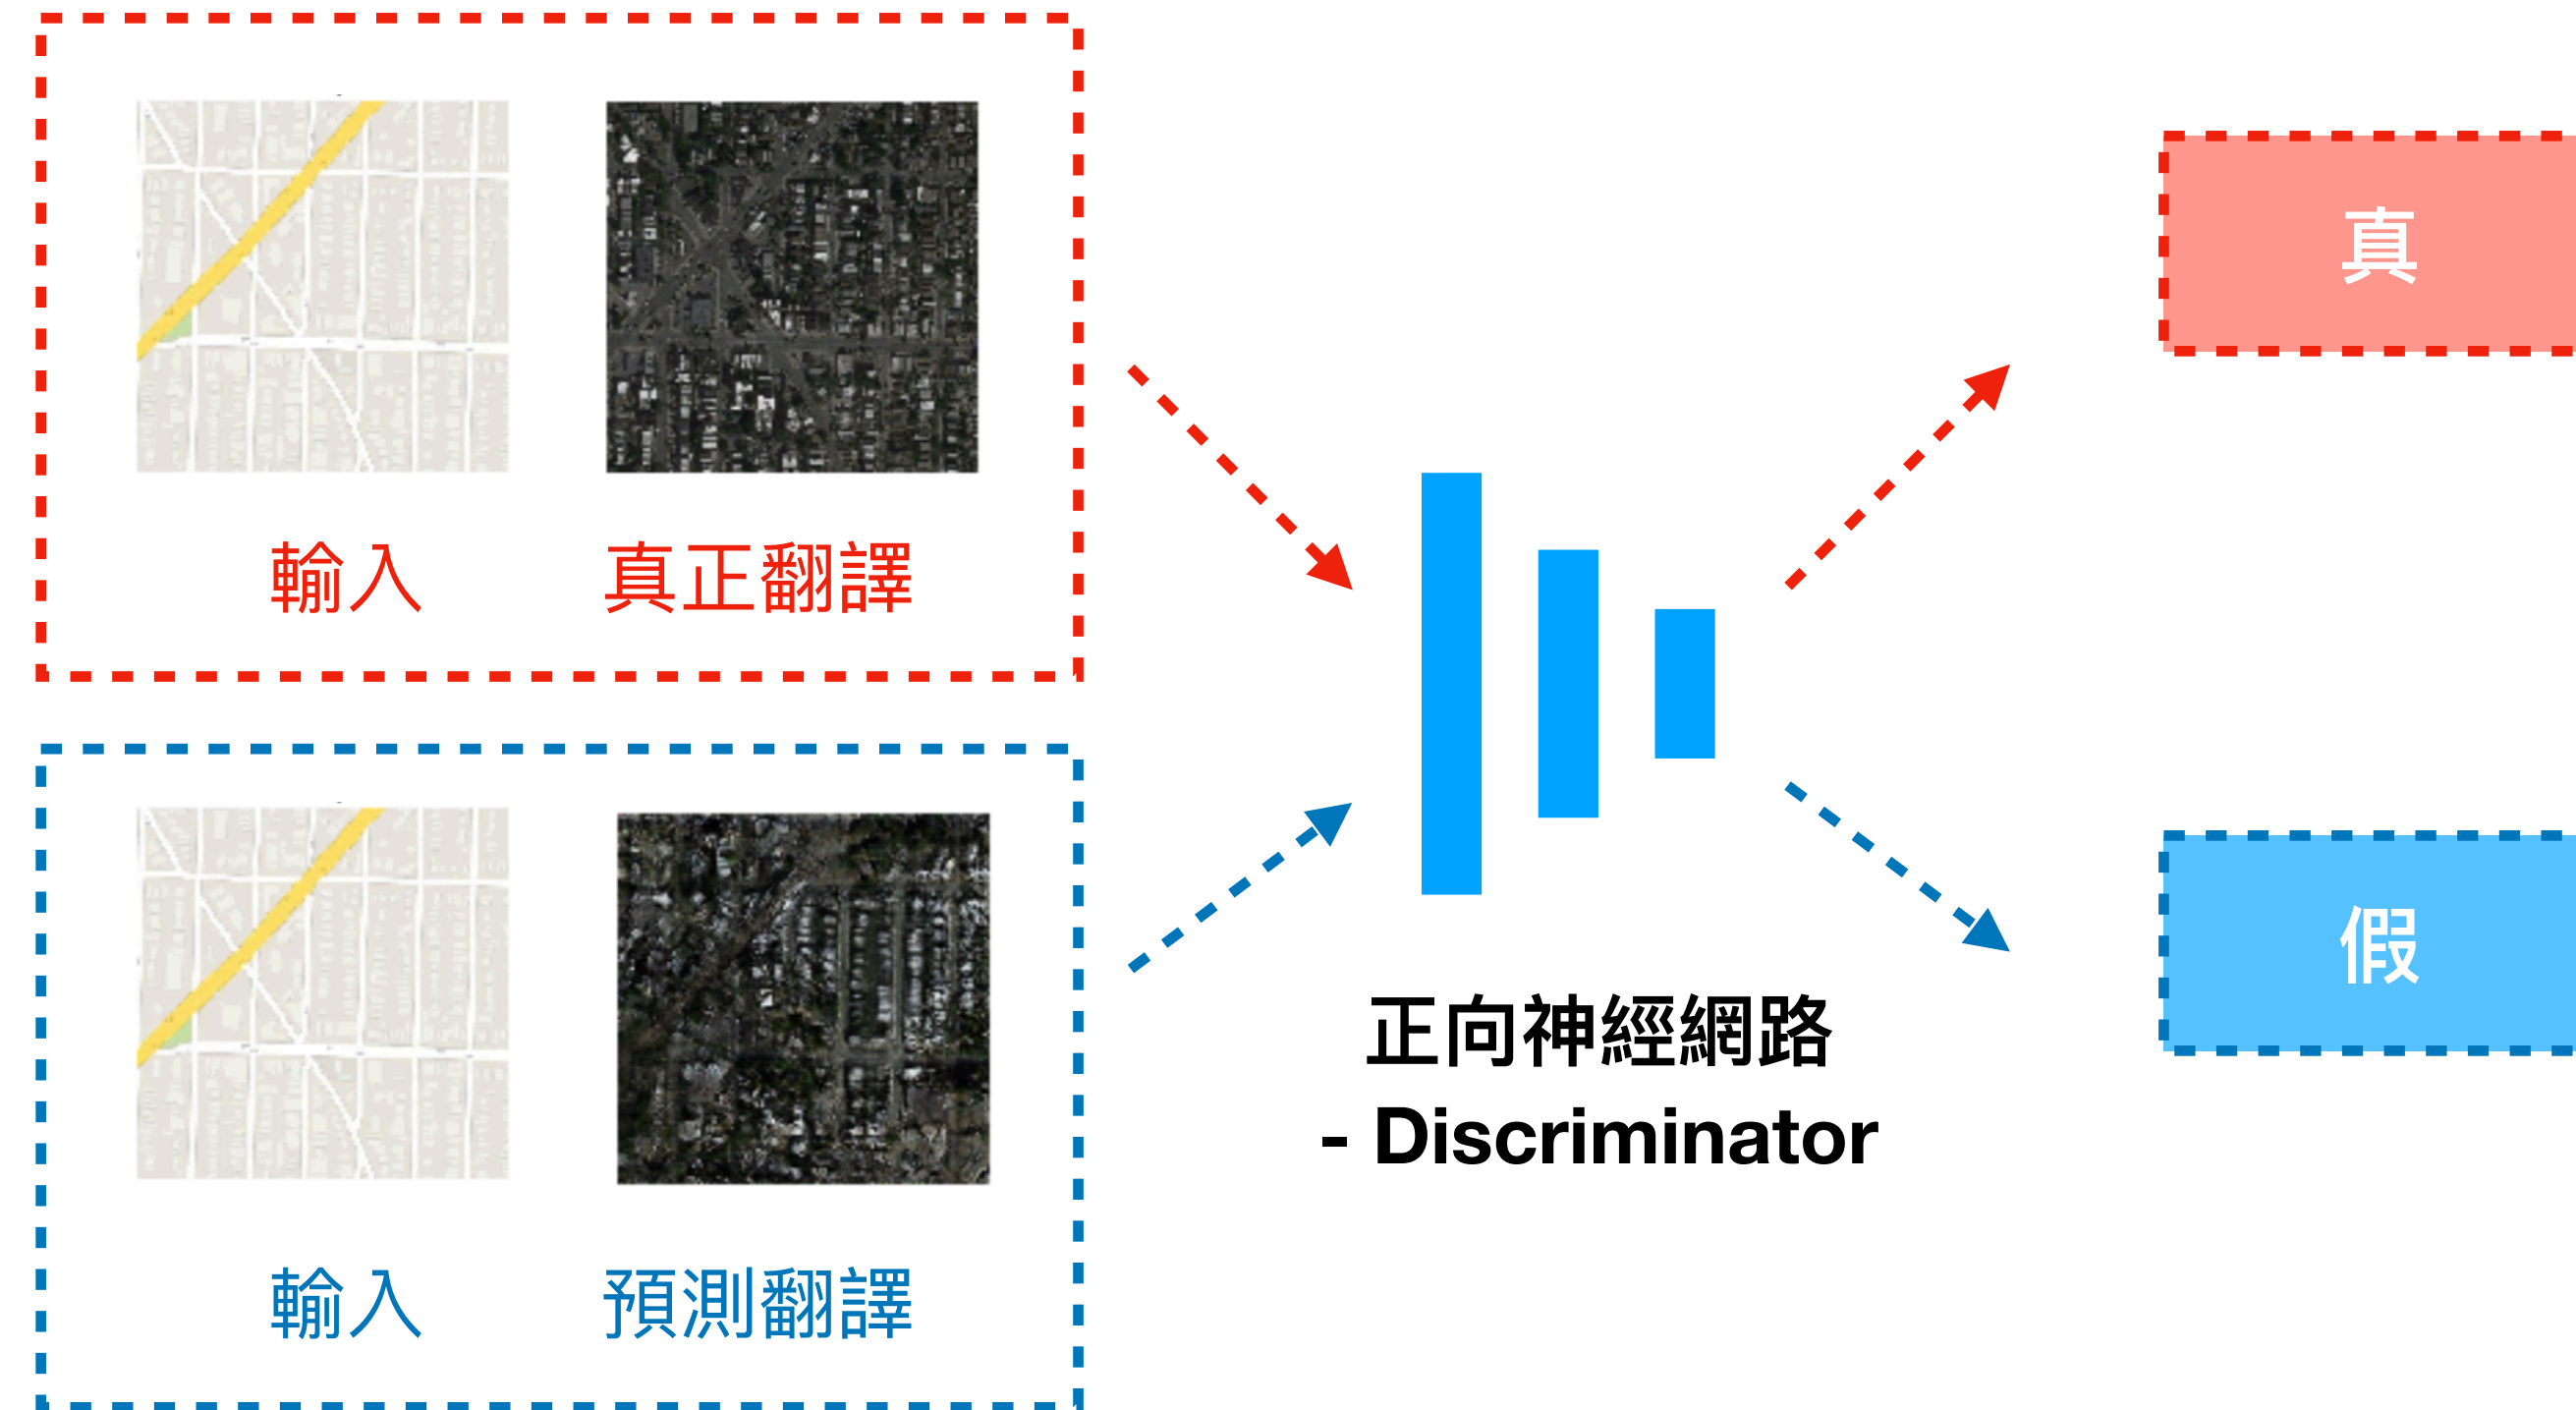
**MSE Loss** = (預測的pixel值 - 正確的pixel值) ^ 2

**MAE Loss** = | 預測的pixel值 - 正確的pixel值 |



使用 **MSE Loss** 或 **MAE Loss** 最大的問題是：假設一個pixel對應到n種真實的草地，但是我們要優化他啊，找到預測最小的誤差，你會發現，最小的誤差就是n種的『**平均**』，但你想像一下，把不同的草地的圖疊一起做平均，對於人眼的感覺，就一個字『**模糊**』！

# GAN Loss




GAN 考慮的基礎是整張圖，而不是一個一個像素，所以你會發現遠看真的超像一個真品的，不過細節就不太行了！



# Loss 大比拼


## GAN Loss

我們看出只用 GAN Loss 的模型的色調是非常像原圖的！甚至是無所不用其極地讓整張圖接近原圖，但細節就完全不行了！



## 傳統(MAE) Loss



傳統Loss就如同我們所說，因為太過關注一個一個pixel，所以導致雖然細節很棒，但過度模糊



## GAN Loss + MAE Loss

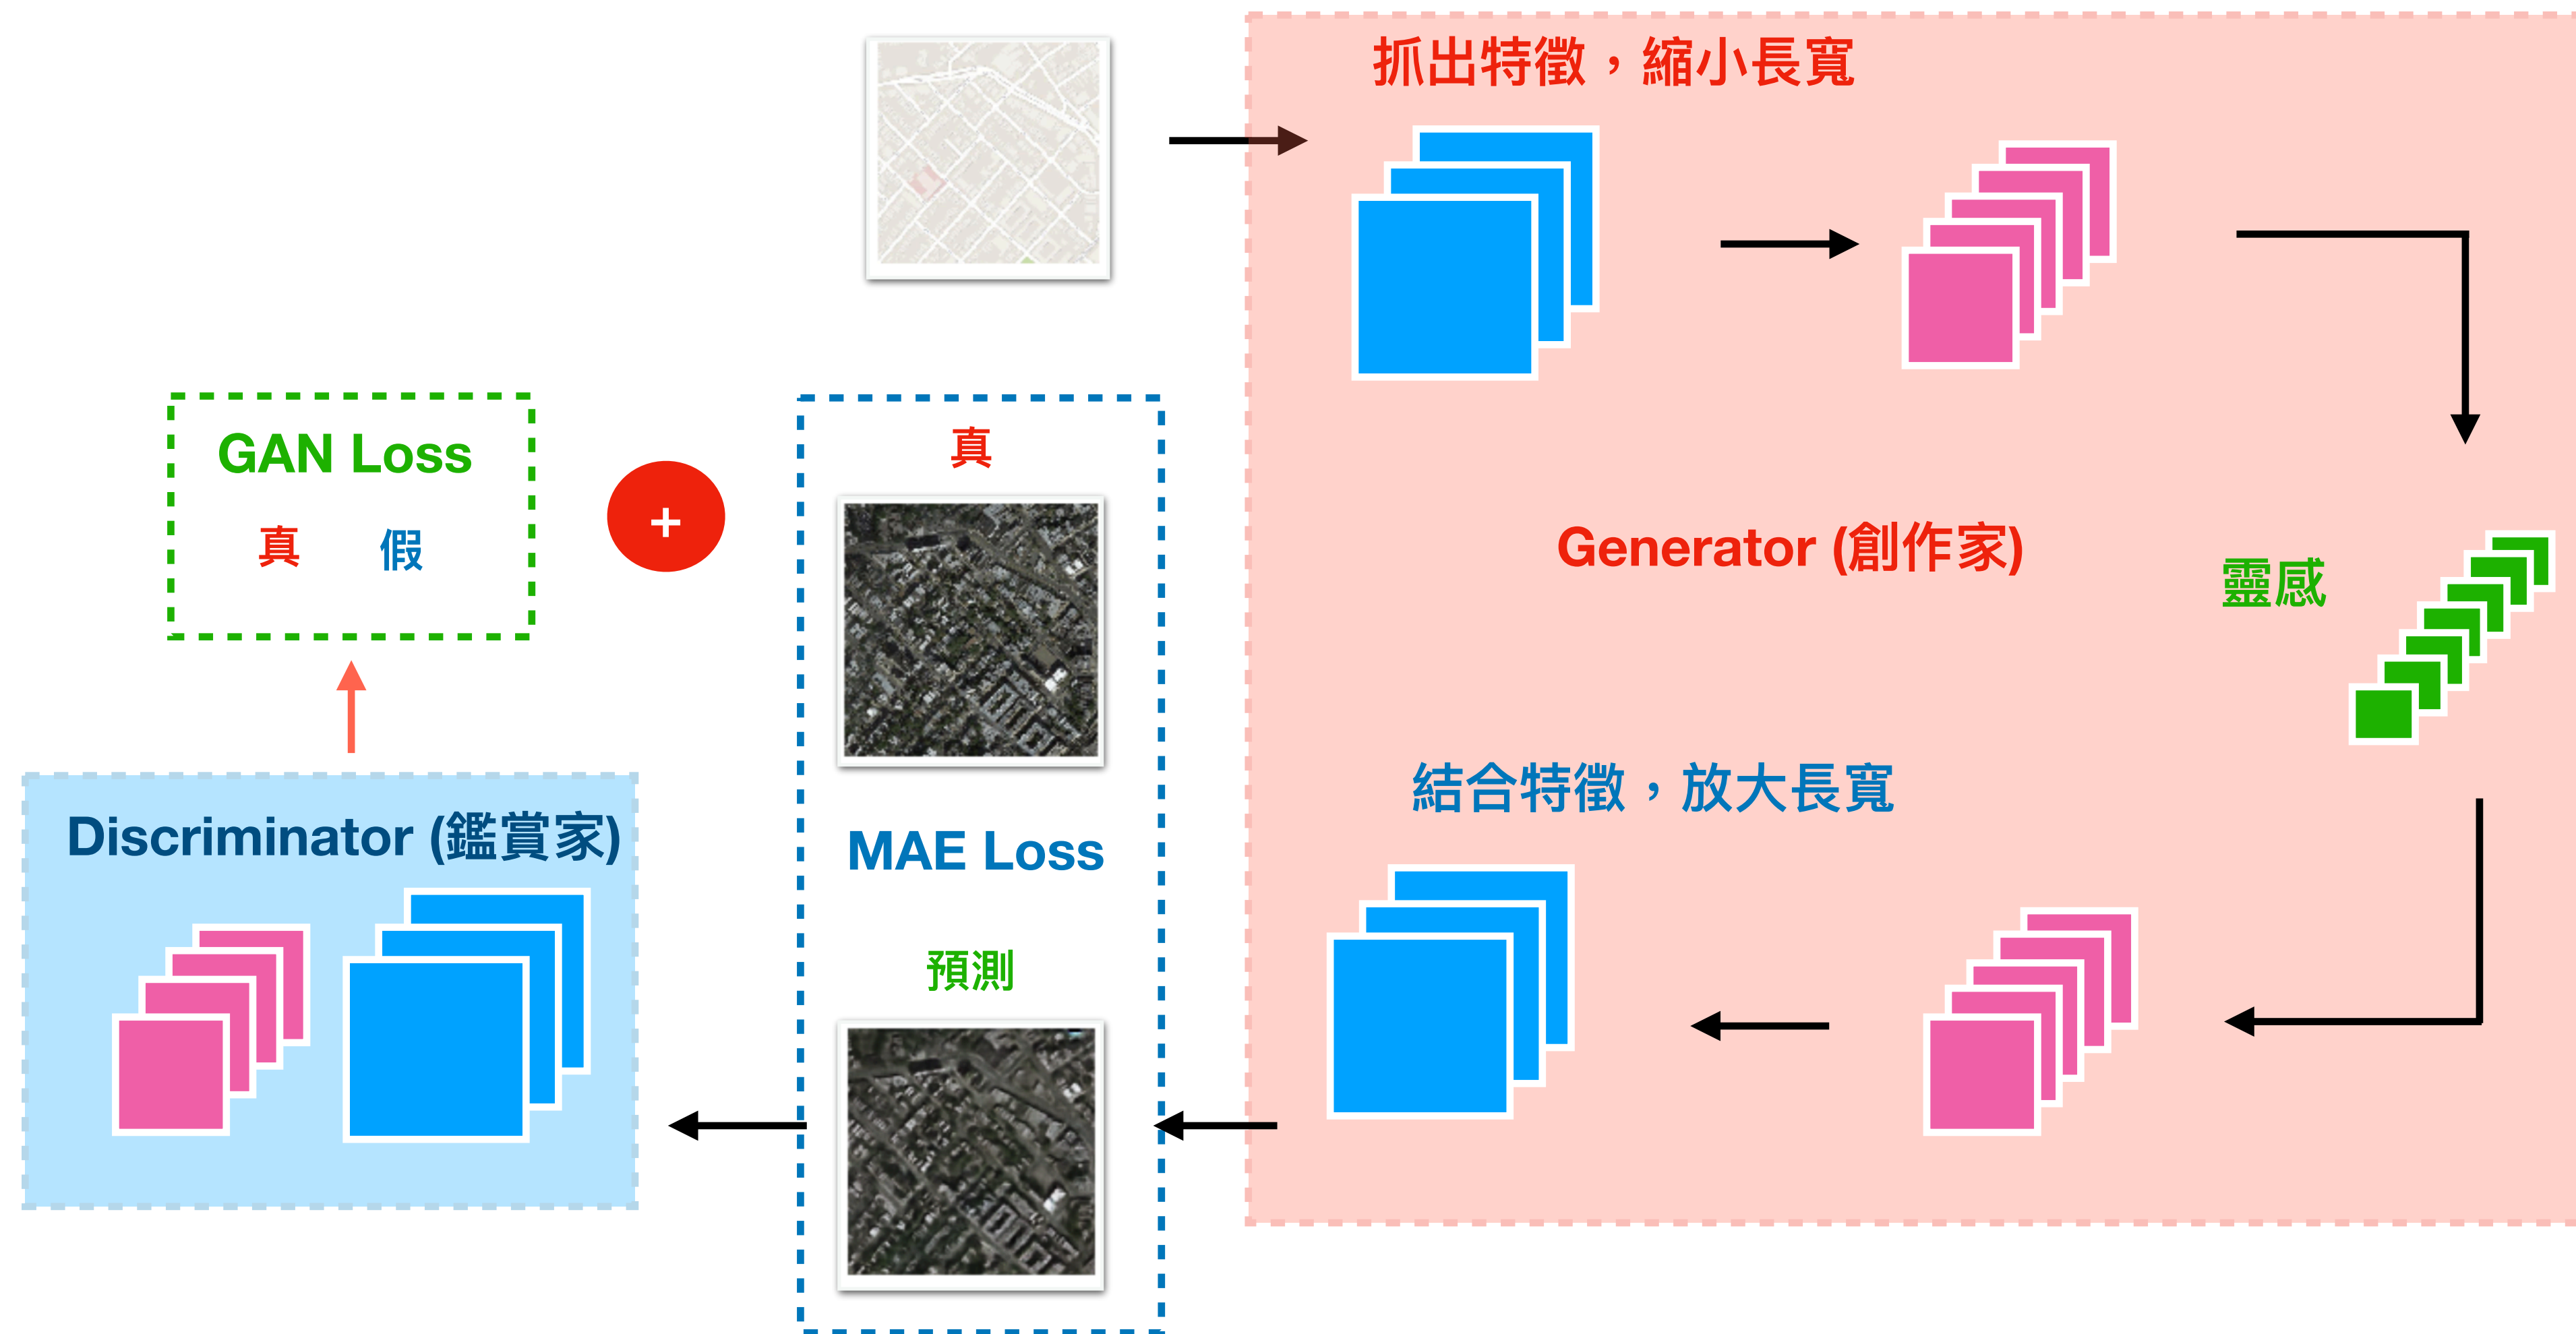
那把兩種方式混在一起就好了！！！你會發現雖然還是有點模糊，但整張圖看起來非常像是真實圖片

勝





# 完整模型



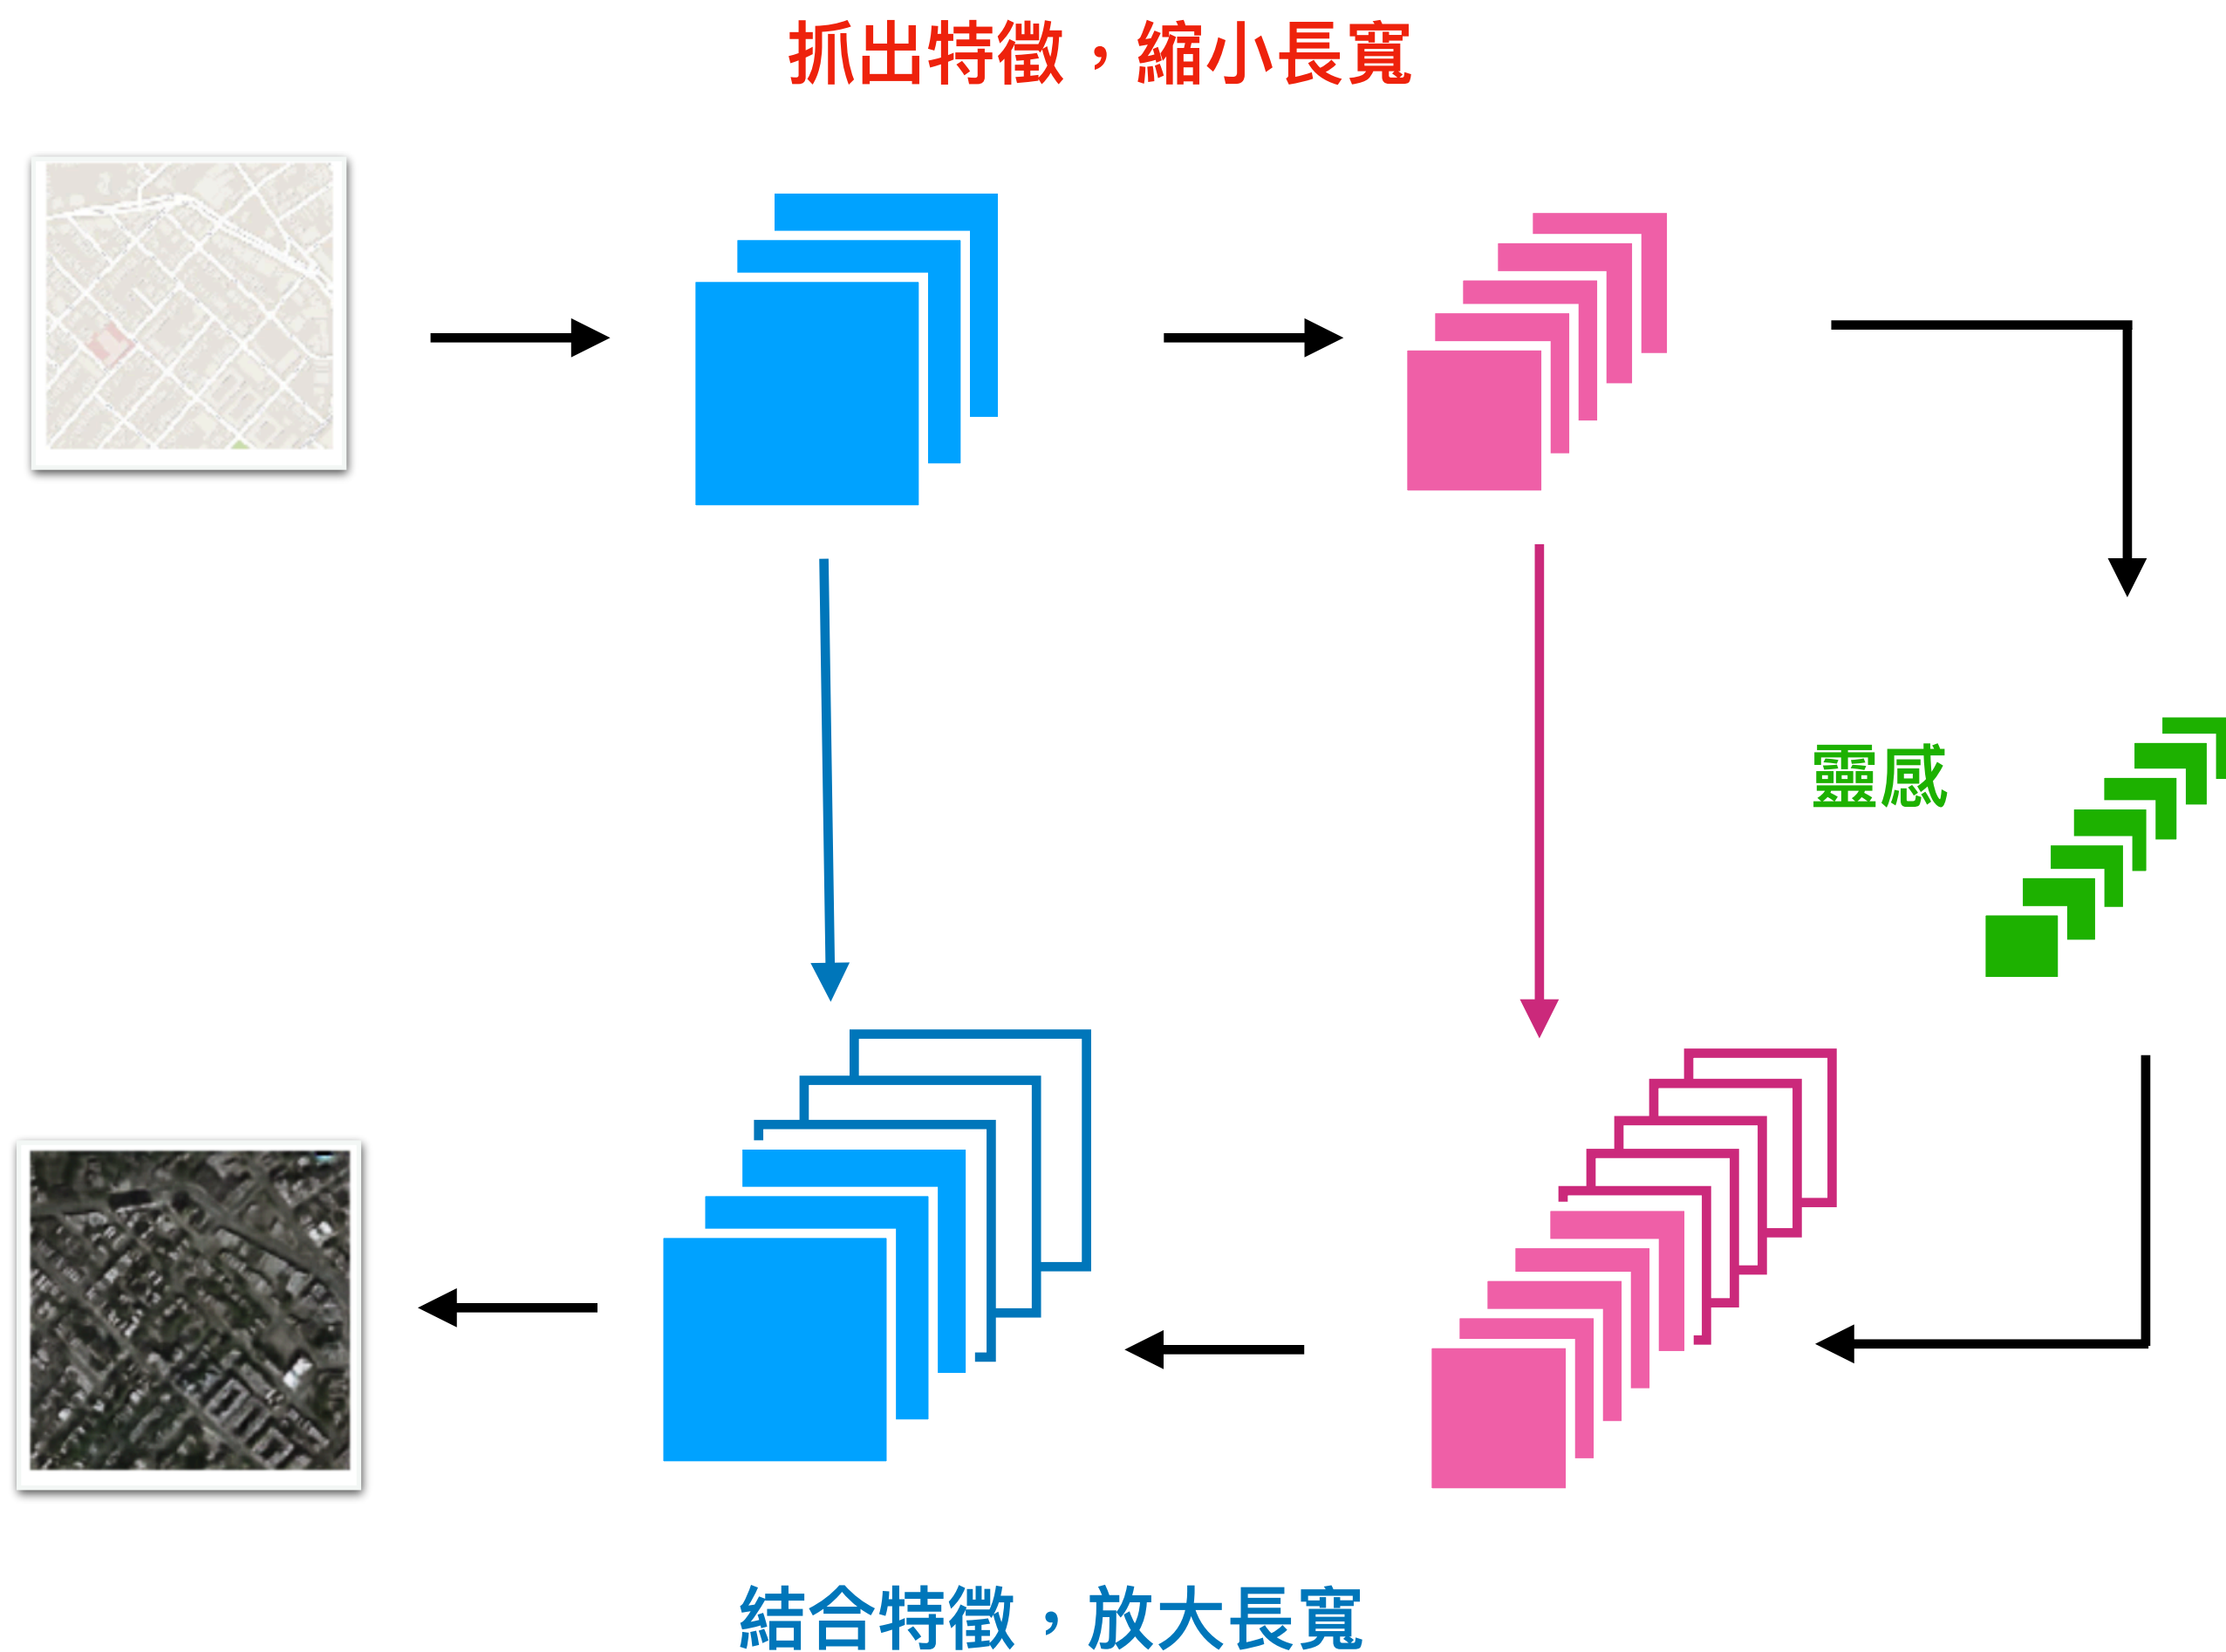
# 創作家 Trick




我們在創作的過程發現一個現象，如果任由創作作家從**靈感**創作，有可能創作出跟原圖差距非常多的圖



所以我們採取了一個方式，把前面抓出的**原圖特徵**當成一個**條件**加到後面，強迫靈感在變成作圖的時候要參照原圖條件，這方式我們叫做**U-Net**



# 鑑賞家 Trick



我們如果只再和以前一樣，針對整張圖輸出真假，就有可能會造成局部的不真，於是我們改成用 每一個區域 給出一個分數的方式來打分





事實上就是把 **MLP** 拿掉，因為卷積後的一個位置就是前面一個區域的給分！這個我們叫做 **FCN(全卷積)**，利用在 **GAN** 上我們會叫做 **PatchGAN**，針對一個Patch(區域) 打分

# 感受野



提到 全卷積(FCN) 或者 PatchGAN 就得提到感受野(Receptive Field)，也就是一個區域的『真/假』到底對應到原圖的多少區域，其實就是所謂的『視野』啦下面我們以 (4, 4) 卷積窗 以及 步長 2 的卷積來說



感受野公式:  $4 + (\text{邊長} - 1) * 2$

層數	感受野大小	公式
1	4	
2	10	$4 + (4 - 1) * 2$
3	22	$4 + (10 - 1) * 2$
4	46	$4 + (22 - 1) * 2$
5	94	$4 + (46 - 1) * 2$


以256的圖片大小，我們通常選四到五層即可！

# GAN Hacks

在這種複雜題目的時候，我們需要面面俱到，步步優化，才有機會生成優秀的圖片，老前輩們總結出了一些小小的優化經驗



## Hack 1. Relu 可以換成 LeakyRelu



還記得我們是在算 梯度: **Loss 對 W 的微分** 吧  
**總體梯度 = 第一層微分 \* 激活微分 \* ...**

所以Relu最大的問題是在『非激活區』微分是 0，所以總體梯度 = 0，也就是不更新的意思，更慘的是，如果這個神經元總是落入『不更新區』，那就意味著他永遠沒機會調整成正確的參數，我們稱之為『**神經元死去**』



Leaky Relu的改進就在，『非激活區』我們會給出『負斜率』，所以就算你進入『非激活區』也會更新參數，至於斜率經過實驗後，**0.2 的負斜率**表現得不錯！



## Hack 2. Adam參數設置

# Adam

[\[source\]](#)

lr = 0.0002    beta\_1 = 0.5

```
keras.optimizers.Adam(lr=0.001, beta_1=0.9, beta_2=0.999, epsilon=M
```


lr (學習速率)

實驗結果：比較小的學習速率  
有助於兩個深度網路的平衡，  
實驗後我們通常會設定成  
0.0002


beta 1(速度剩餘)

實驗結果：Adam有累積速度，但是速度累積的時候當然  
要考慮『摩擦力』，**新速度 = beta\_1 \* 舊原有速度 + (1**  
**- beta\_1) \* 新瞬時速度**，我們會想要設定成0.5，你可以  
當成前一秒的速度會因為摩擦力在這一秒只剩下 **50%**

# 不對稱圖像翻譯



我們之前已經學會了 PIX2PIX，利用 GAN 讓圖片能夠翻譯成另外的圖片，但你有沒有發現我們的訓練資料都是『**成對**』出現，因為如果沒『**成對**』出現的話，我們無法 **對答案 (傳統loss部分)**！



但現實生活我們有時候不太可能找到『**成對**』的翻譯，譬如：我要做出 **馬 <-> 斑馬** 的翻譯 或者 **風景 <-> 油畫** 的翻譯，我們不可能找出一樣位置的馬和斑馬或者跟風景一模一樣的**油畫**，那該怎麼辦呢？讓 **CycleGAN** 教你如何做！




# 天才一般的想法

- ！ 假設我的輸入是馬，我想要轉換成斑馬，但我又沒有對稱圖片對答案
- ！ 我難道不能用另外一套 Generator 轉換回 馬，來對答案嗎！
- ！ 天才！這就是CycleGAN的精髓，運用兩套PIX2PIX組合起來對答案



轉換前



轉換後



# 完整模型

